Lokális visszalépési mechanizmusok a generatív modellezésben

Molnár Máté Norbert
PTI BSc

Témavezető:
Dr. Tajti Tibor

2025

Definíciók

Definíciók

Legyen M egy előre betanított nagy nyelvi modell a Transformer architektúrán alapulva[3], amely tokenekből álló szókészlet V-nek egy véges sorozatára visszaadja a logitok vektorát. M generálási folyamata $t = 1, 2, \ldots$ lépésekben:

- $z_t = M(x_{1:t-1})$,
- $p_t = softmax(z_t)$,
- $x_t \sim p_t$,

ahol $x_{1:t}$ a t. lépésig generált elemek sorozata.

Hipotézis

Probléma

- Ha x_t egyszer rögzítésre kerül, az minden további lépésnél a kontextusban marad.
- Korai hibák elronthatják a generálási folyamatot.

Megoldás

Egy *feltételes visszalépési operátor* bevezetése, amely megadott lépésekben eltávolíthatja az utolsó n tokent, egy kritériumnak megfelelően. Hipotézisünk, hogy ez javíthatja a generálás minőségét.

Feltételes visszalépés

Rögzítsünk egy ellenőrzési pont időszakot $\kappa \in \mathbb{N}$. Minden t lépésnél, ahol $t \bmod \kappa = 0$ kiértékeljük a következő értéket:

$$\delta : \mathbb{R}^{|\mathcal{V}|} \times \Delta_{|\mathcal{V}|} \times \mathcal{V} \times \{0, 1, \ldots, |\mathcal{V}| - 1\} \longrightarrow \{0, 1, \ldots, t\},$$

$$n_t \;=\; \delta\big(z_t, p_t, x_t, i_t; \Theta\big),$$

ahol

- δ a visszalépés feltétele,
- Θ összegyűjti a hiperparamétereket,
- i_t pedig x_t indexe $\mathcal{V}$-ben, $i_t \in \{0, 1, \ldots, |\mathcal{V}| - 1\}$.

Feltételes visszalépés

Ha $n_t > 0$, töröljük $x_{t-n_t+1:t}$ útótagot, és folytatjuk a generálást $x_{1:t-n_t}$-ről. A belső Transformer állapotát ennek megfelelően szintén visszatekerjük[1].

[1] Az összes tokenhez múltbeli kulcs- és érték-tenzorokat tartunk fenn, ezeket a szöveges szekvenciával együtt csonkítjuk.

Feltételes visszalépési operátorok

Többfajta feltételes visszalépési operátort is implementáltunk:

- Valószinűség küszöbérték
- Entrópia küszöbérték
- Valószínűség határ
- Valószínűség csökkenés
- Valószínűség trend
- Ismétlés
- N-gram átfedés
- Logit küszőbérték

Értékelés

Értékelés módja

- HumanEval benchmark[1],
- Qwen-2.5-Coder-7B-Instruct [2] és Qwen2.5-0.5B-Instruct [4],
- elsődleges mérőszám a helyesen generált programok százalékos aránya,
- minden kisérlet esetén a standard generálási paramétereket állandó értéken tartottuk.

```
def truncate_number(number: float) -> float:
    """ Given a positive floating point number, it can be decomposed into
    and integer part (largest integer smaller than given number) and decimals
    (leftover part always smaller than 1).

    Return the decimal part of the number.
    >>> truncate_number(3.5)
    0.5
    """
----
    return number - int(number)
```

1. ábra. Egy eleme a benchmarknak

Eredmények a Qwen2.5-0.5B-Instruct modellen

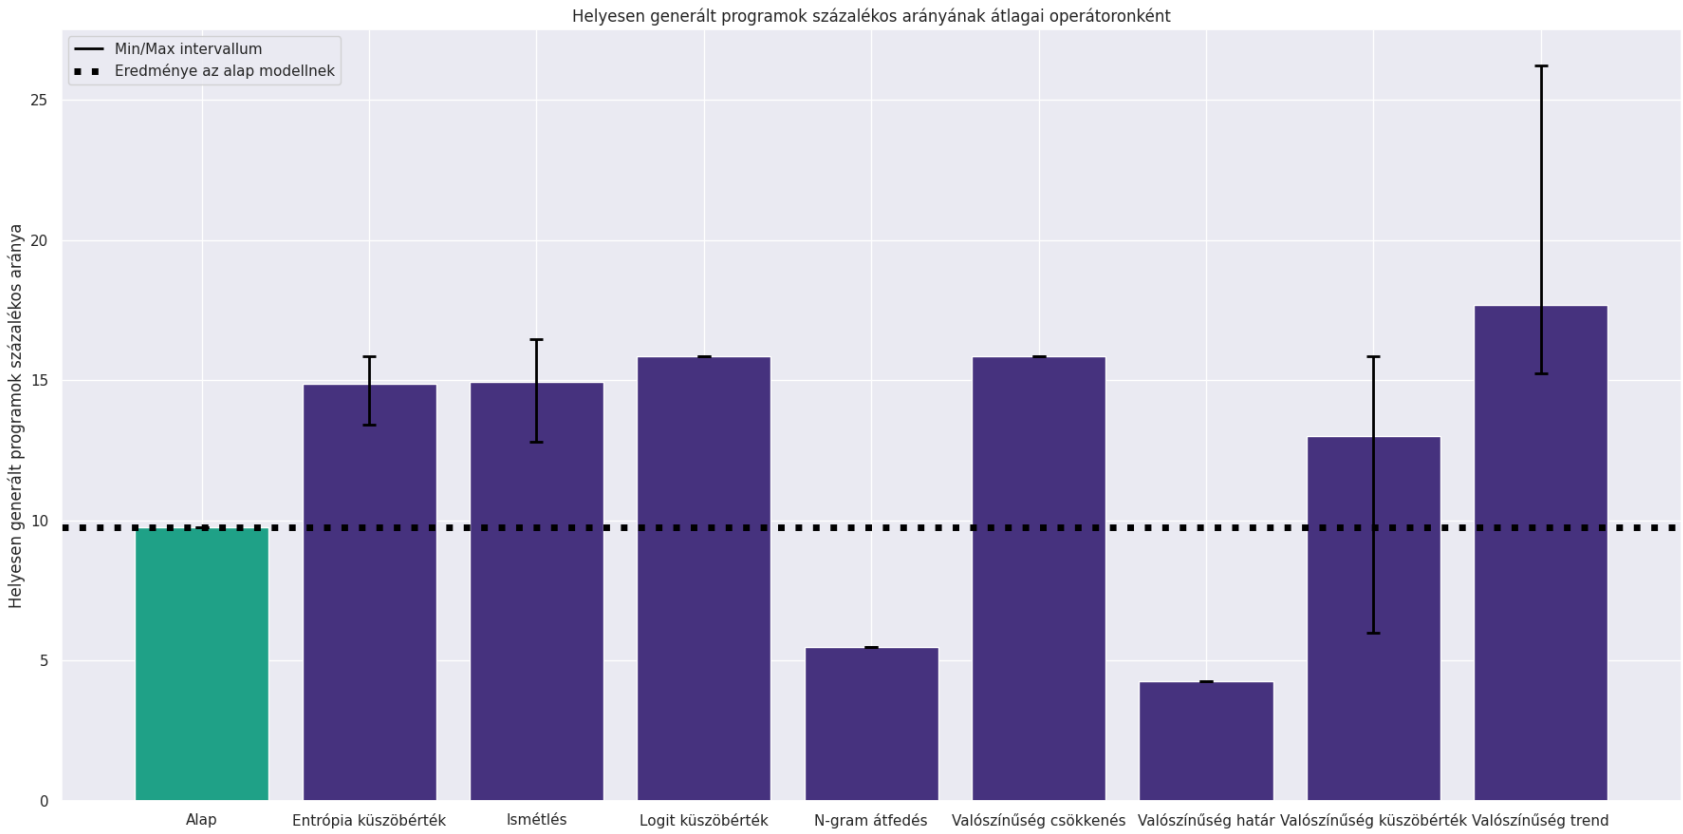

2. ábra. Helyesen generált programok százalékos arányának átlagai operátoronként

Értékelés

Eredmények a Qwen-2.5-Coder-7B-Instruct modellen

TODO: Logit küszöbérték

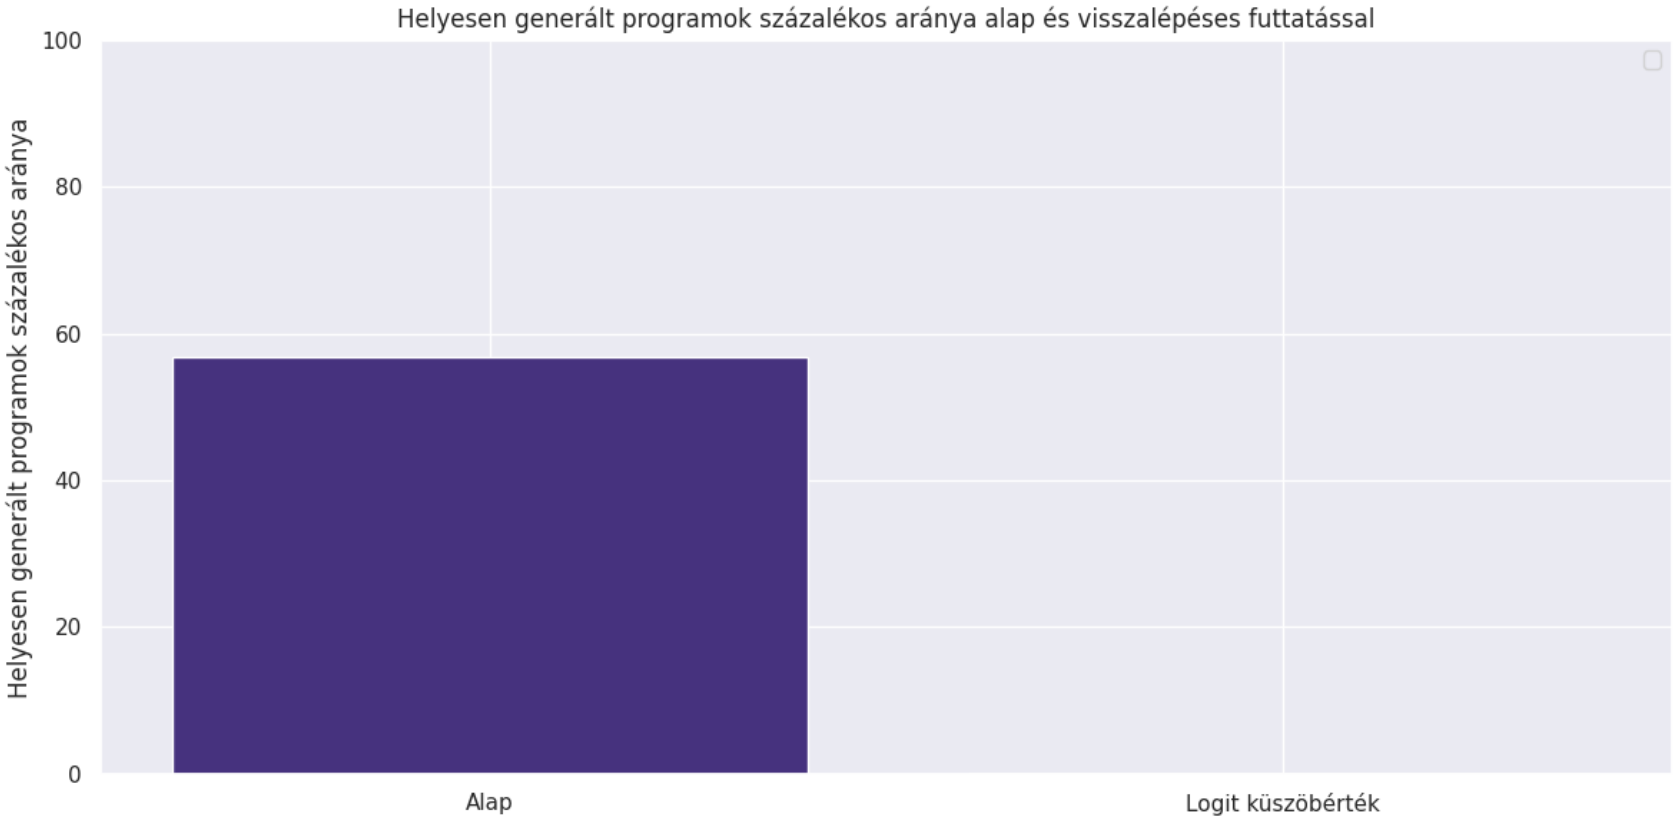

3. ábra. Helyesen generált programok százalékos aránya alap és visszalépéses model futtatásnál nagy modellen

Értékelés

Generált token/másodperc a Qwen2.5-0.5B-Instruct modellen alap és visszalépéses futtatással

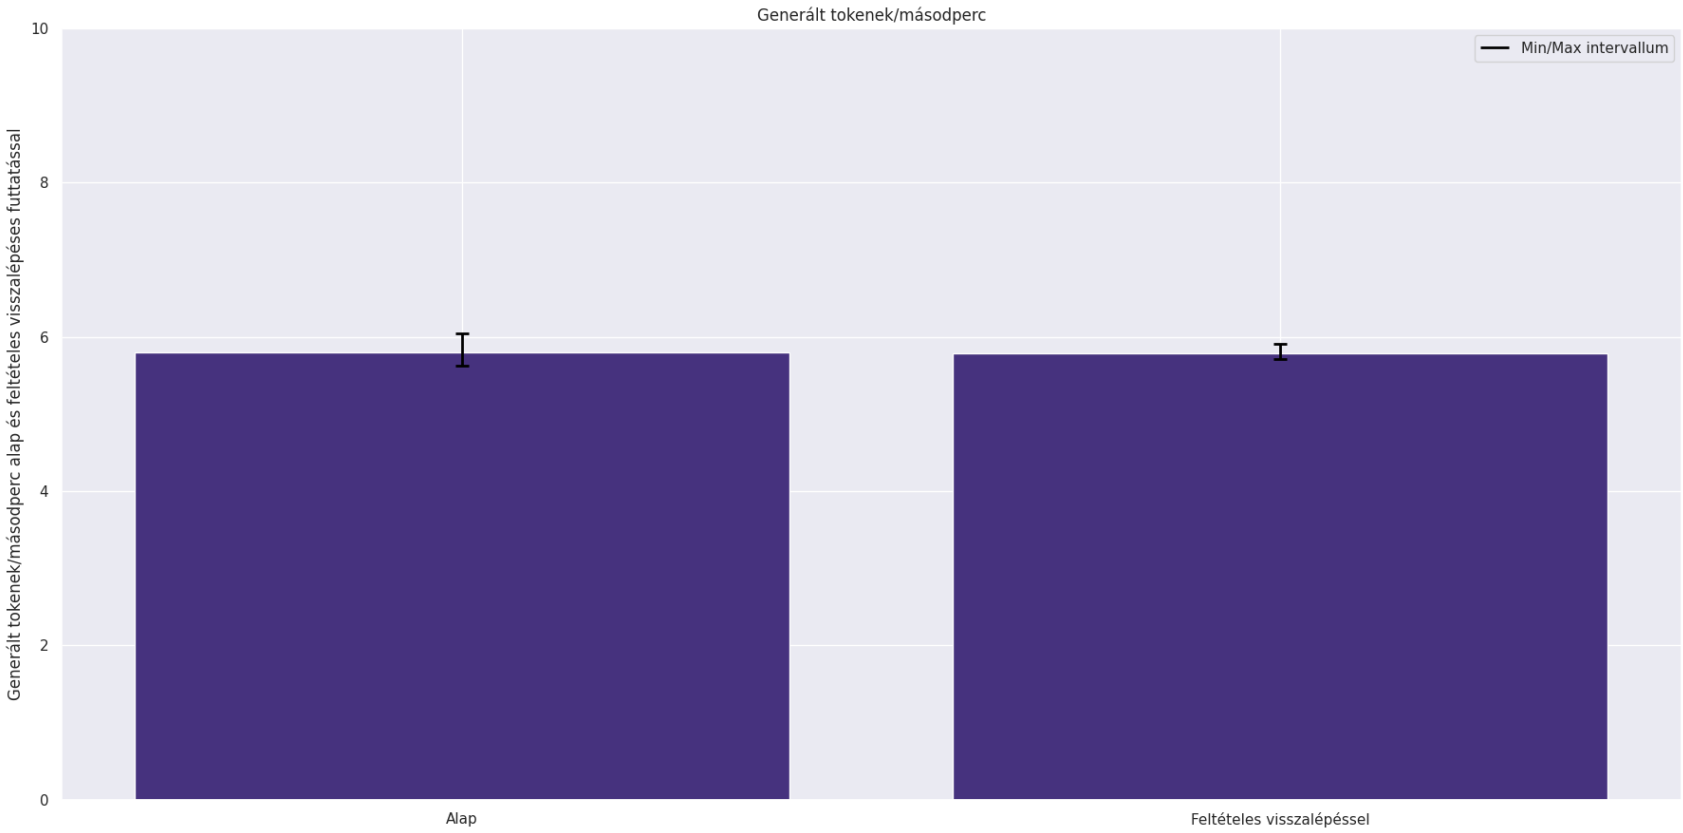

4. ábra. Generált token/másodperc összehasonlítása alap és visszalépéses futtatással

Jövőbeli tervek

- Még nagyobb modellen kiértékelés.
- Több visszalépési operátor kidolgozása.
- Neurális háló felépítése és betanítása a visszalépési operátorra.
- Hiperparaméterek optimalizálására okosabb algoritmussal.

Referenciák

[1] Mark Chen és tsai. *Evaluating Large Language Models Trained on Code*. 2021. arXiv: 2107.03374 [cs.LG]. URL: https://arxiv.org/abs/2107.03374.

[2] Binyuan Hui és tsai. *Qwen2.5-Coder Technical Report*. 2024. arXiv: 2409.12186 [cs.CL]. URL: https://arxiv.org/abs/2409.12186.

[3] Ashish Vaswani és tsai. *Attention Is All You Need*. 2023. arXiv: 1706.03762 [cs.CL]. URL: https://arxiv.org/abs/1706.03762.

[4] An Yang és tsai. *Qwen2 Technical Report*. 2024. arXiv: 2407.10671 [cs.CL]. URL: https://arxiv.org/abs/2407.10671.

Köszönöm a figyelmet!